УДК 004.9:331.522

АВТОМАТИЗИРОВАННЫЙ АНАЛИЗ IT-ВАКАНСИЙ СНГ СРЕДСТВАМИ PYTHON: ОЦЕНКА ВЛИЯНИЯ НАВЫКОВ НА ЗАРАБОТНУЮ ПЛАТУ И ПРОГНОЗИРОВАНИЕ СПРОСА

Тарасевич А.Н., Банников Н.Д., студенты гр. 572302

Белорусский государственный университет информатики и радиоэлектроники
г. Минск, Республика Беларусь

Научный руководитель: Полоско Е.И., старший преподаватель кафедры экономической информатики

Аннотация. В работе исследуется динамика квалификационных требований и факторов оплаты труда в IT-отрасли стран СНГ на основе автоматизированного анализа репрезентативной выборки из 2 472 актуальных вакансий, собранных средствами языка Python. Предложен алгоритм двухэтапной экстракции компетенций с нормализацией синонимов и защитой от контекстных коллизий. Проведена эконометрическая оценка зарплатных премий за технологические навыки с проверкой статистической гипотезы по непараметрическому U-критерию Манна-Уитни. Построены и сопоставлены прогнозные модели заработной платы (Baseline, Ridge, Random Forest), показавшие превосходство ансамблевого подхода (R^2 = 0,563, снижение средней абсолютной ошибки MAE на 39,3%). С использованием линейной модели экспоненциального сглаживания Холта выполнен среднесрочный прогноз динамики спроса на ключевые компетенции с расчетом 95%-х доверительных интервалов.

Ключевые слова: анализ рынка труда, IT-вакансии, Python, заработная плата, Skill Premium, критерий Манна-Уитни, Random Forest, прогнозирование спроса, модель Холта, HeadHunter API.

Введение

Современный рынок труда в сфере информационных технологий характеризуется высокой динамичностью, фрагментацией квалификационных требований и структурным дисбалансом спроса и предложения. Традиционные методы мониторинга рынка труда, основанные на периодических социологических опросах и агрегированной государственной статистике, обладают значительным временным лагом (от квартала до года) и не позволяют фиксировать локальные сдвиги в востребованности прикладных библиотек, фреймворков и инструментов разработки.

Автоматизированный анализ структурированных и неструктурированных данных онлайн-платформ рекрутинга (HeadHunter, rabota.by) методами интеллектуального анализа данных (Data Mining) и машинного обучения открывает возможности для непрерывного мониторинга рынка труда в режиме реального времени. Актуальность исследования обусловлена необходимостью количественной оценки вклада конкретных компетенций в уровень оплаты труда

специалистов, а также построения упреждающих прогнозов спроса для оптимизации образовательных программ профильных вузов.

Цель работы — разработка программного инструментария автоматизированного сбора и анализа IT-вакансий стран СНГ, выявление статистически значимых премий за технологические навыки и моделирование краткосрочной динамики спроса на ключевые компетенции.

Теоретико-методологическая база исследования

1. Нормализация заработной платы. Для устранения курсовых и налоговых искажений введена стандартизованная метрика чистого дохода (net midpoint) в единой базовой валюте — белорусских рублях (BYN):

$$W_net = ((S_from + S_to) / 2) \cdot K_curr \cdot (1 - T_gross) \quad (1)$$

где S_from, S_to — нижняя и верхняя границы декларируемой заработной платы; K_curr — курс конвертации валюты к BYN (1,0 для BYN; 0,034 для RUB; 3,30 для USD; 3,55 для EUR; 0,0068 для KZT); T_gross — индикатор налогового вычета (T_gross = 0,13 при отметке gross = true, компенсирующий подоходный налог 13%, и 0 при отметке net). При наличии единственной границы принимается соответствующее граничное значение.

2. Эконометрическая оценка премии за навык. Для каждого i-го навыка рассчитывается относительная надбавка к заработной плате (Skill Premium, SP_i):

$$SP_i = ((Med(W \mid S_i = 1) - Med(W \mid S_i = 0)) / Med(W \mid S_i = 0)) \cdot 100\% \quad (2)$$

где Med(W | S_i = 1) и Med(W | S_i = 0) — медианы заработной платы вакансий, содержащих и не содержащих требование к навыку i соответственно. Ввиду правосторонней асимметрии распределений проверка гипотезы H0 о равенстве распределений осуществляется по непараметрическому двустороннему U-критерию Манна-Уитни:

$$U = n_1 \cdot n_2 + (n_1 \cdot (n_1 + 1)) / 2 - R_1 \quad (3)$$

где n_1, n_2 — объемы выборок вакансий с навыком и без него; R_1 — сумма рангов первой выборки. Статистическая значимость принимается при p-value < 0,05.

3. Моделирование заработной платы. Оценка связи вектора квалификационных признаков X и уровня оплаты труда формулируется как задача многомерной регрессии:

$$W_pred = f(X_exp, X_loc, X_fmt, X_count, S_1, S_2, ..., S_m) \quad (4)$$

где X_exp, X_loc, X_fmt — бинарные индикаторы уровня требуемого опыта, страны и формата работы; X_count — общее число требуемых навыков; $S_j \in \{0, 1\}$ — бинарные индикаторы владения j-й технологией из топ-50 рынка. Точность оценивается по коэффициенту детерминации R^2 и средней абсолютной ошибке MAE:

$$R^2 = 1 - (\sum(y_k - \hat{y}_k)^2 / \sum(y_k - \bar{y})^2), \quad MAE = (1/N) \cdot \sum |y_k - \hat{y}_k| \quad (5)$$

4. Моделирование рыночного спроса на компетенции. Суточный индекс проникновения (рыночного спроса) на технологию i определяется как:

$$D_i(t) = (V_i(t) / V_total(t)) \cdot 100\% \quad (6)$$

где V_i(t) — количество вакансий в день t, содержащих навык i; V_total(t) — общее число опубликованных IT-вакансий в день t. Для устранения недельной сезонности рассчитывается 7-дневное скользящее среднее D_smooth(t). Прогнозирование тренда на горизонт h осуществляется линейной моделью Холта:

$$\ell_t = \alpha \cdot y_t + (1 - \alpha) \cdot (\ell_\{t-1\} + b_\{t-1\}) \quad (7)$$

$$b_t = \beta \cdot (\ell_t - \ell_\{t-1\}) + (1 - \beta) \cdot b_\{t-1\} \quad (8)$$

$$\hat{y}_\{t+h\} = \ell_t + h \cdot b_t \quad (9)$$

где ℓ_t — экспоненциально сглаженный уровень ряда; b_t — оценка наклона тренда; α, β ∈ (0, 1) — сглаживающие параметры, оптимизируемые методом максимального правдоподобия. Асимптотические 95%-е доверительные границы прогноза рассчитываются как ŷ_{t+h} ± 1,96 · σ_resid с отсечением по границам [0; 100%].

Экспериментальное исследование и результаты

Характеристика эмпирической базы. Сбор первичных данных осуществлялся с использованием разработанного Python-модуля взаимодействия с открытым REST API платформы HeadHunter (с региональной маршрутизацией через rabota.by для белорусского сегмента). Генеральная совокупность охватывает 2 472 актуальные IT-вакансии, опубликованные в период с 29 сентября по 9 ноября 2026 года. Параметры выборки приведены в таблице 1.

Таблица 1 — Параметры сформированного массива данных

Параметр выборки	Значение показателя
Всего собранных вакансий	2 472
Вакансии с валидной заработной платой	817 (33,1%)
Географический охват: Беларусь	1 132 (45,8%)
Географический охват: Россия	820 (33,2%)
Географический охват: Казахстан	520 (21,0%)
Общий объем канонической таксономии навыков	187 технологий
Вакансии с идентифицированными компетенциями	2 029 (82,1%)
Среднее число навыков на вакансию	5,46

Экстракция навыков. Разработанный синтаксический анализатор производит сопоставление нормализованных синонимов (более 400 алиасов) с ключевыми полями key_skills и полным текстом описания с использованием контекстно-

зависимых регулярных выражений, предотвращающих ложные срабатывания служебных лексем («Go», «C», «R», «SOLID»).

Эконометрический анализ премий. В таблице 2 представлены результаты расчета премий для ключевых технологий, упорядоченных по величине относительного прироста заработной платы.

Таблица 2 — Оценка зарплатных премий за технологические навыки (Skill Premium)

Навык / Технология	Вакансий	Разность, BYN	Премия, %	p-value	Значимость
Go (Golang)	22	+4 506,70	+112,86	$3{,}21 \cdot 10^{-4}$	p < 0,001 (***)
MongoDB	17	+3 523,70	+89,06	$1{,}07 \cdot 10^{-4}$	p < 0,001 (***)
RabbitMQ	42	+3 075,70	+80,94	$2{,}78 \cdot 10^{-8}$	p < 0,001 (***)
CI/CD	76	+2 993,60	+79,37	$1{,}36 \cdot 10^{-9}$	p < 0,001 (***)
Kubernetes	50	+3 039,60	+79,05	$1{,}29 \cdot 10^{-7}$	p < 0,001 (***)
Apache Kafka	48	+3 000,00	+78,95	$2{,}06 \cdot 10^{-8}$	p < 0,001 (***)
Redis	53	+2 828,60	+75,00	$4{,}95 \cdot 10^{-8}$	p < 0,001 (***)
ClickHouse	28	+2 890,00	+73,91	$2{,}07 \cdot 10^{-6}$	p < 0,001 (***)
Docker	158	+2 073,80	+51,85	$1{,}42 \cdot 10^{-13}$	p < 0,001 (***)
PostgreSQL	178	+1 600,00	+40,00	$8{,}91 \cdot 10^{-10}$	p < 0,001 (***)

Из таблицы 2 следует, что наибольшую относительную премию обеспечивают компетенции в области высоконагруженных серверных систем (Go — +112,9%, RabbitMQ — +80,9%, Kafka — +79,0%) и контейнерной оркестрации (Kubernetes — +79,1%, CI/CD — +79,4%). Все полученные надбавки обладают высокой степенью статистической достоверности ($p < 0{,}001$).

Результаты моделирования заработной платы. На основе 817 наблюдений проведено обучение и сравнительный анализ трех моделей регрессии. Обучающая выборка — 80% (N = 653), тестовая — 20% (N = 164), выполнена 5-кратная кросс-валидация. Результаты приведены в таблице 3.

Таблица 3 — Сравнительная точность моделей прогнозирования заработной платы

Модель	R^2 (Test)	MAE, BYN	RMSE, BYN	5-Fold CV R^2
Baseline (константная медиана)	-0,148	2 392,9	3 183,9	-0,082 ± 0,024
Гребневая регрессия (Ridge, α = 1,0)	0,456	1 666,4	2 192,6	0,338 ± 0,130
Случайный лес (Random Forest)	0,563	1 452,5	1 963,5	0,459 ± 0,103

Модель случайного леса (Random Forest) продемонстрировала наилучшие аппроксимационные свойства, объясняя 56,3% дисперсии заработной платы и снижая ошибку MAE на 940,4 BYN (-39,3%) относительно базового уровня. Анализ

важности признаков показал, что ведущими предикторами выступают квалификационный грейд (Senior — 18,8%, Middle+ — 16,2%), офисный формат работы (8,9%), региональная принадлежность (Беларусь — 8,5%) и плотность технологического стека (число навыков — 8,0%).

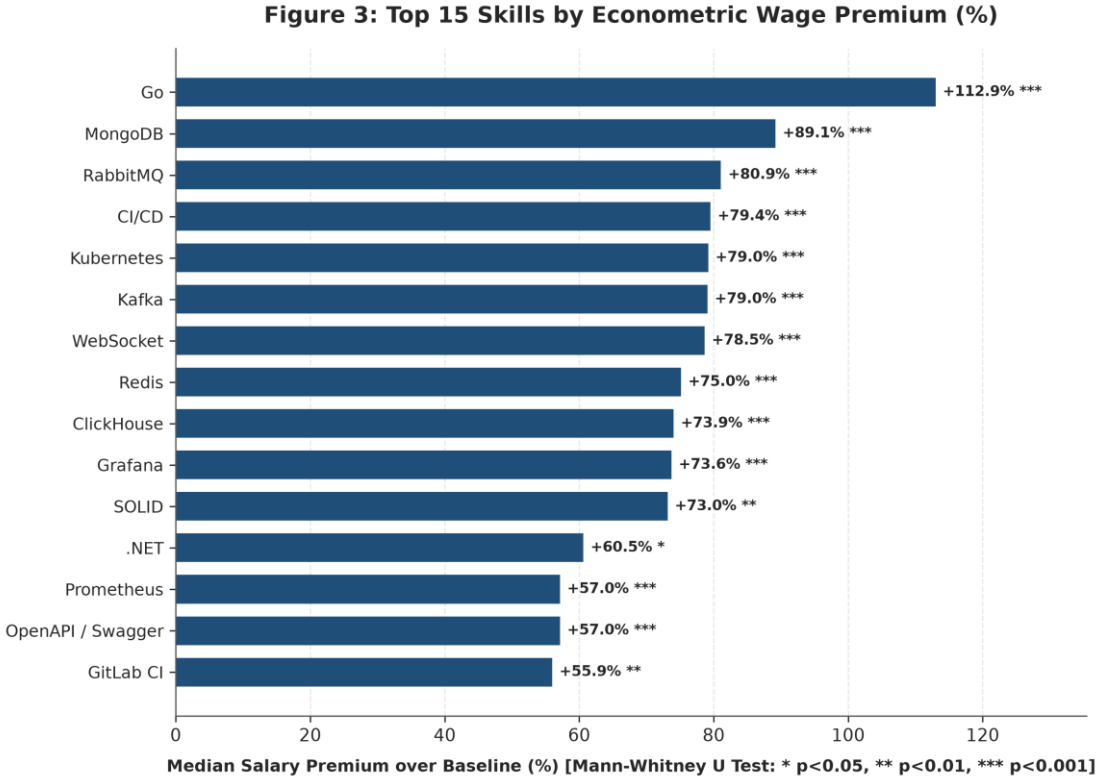


Рисунок 1 — Оценка зарплатных премий за технологические навыки (Skill Premium, %)

Прогнозирование динамики спроса. В таблице 4 приведены результаты прогнозирования долей востребованности на горизонт h = 14 дней на основе модели экспоненциального сглаживания Холта.

Таблица 4 — Результаты прогнозирования рыночного спроса на ключевые технологии

Технология	Доля D_t, %	Прогноз D_{t+14}, %	Прирост Δ, %	Классификация тренда	MAPE, %
Linux	26,37	33,58	+27,33	Высокий рост (High Growth)	13,44
Docker	19,14	20,29	+5,98	Высокий рост (High Growth)	12,21
Git	18,28	19,13	+4,65	Базовый стабильный (Evergreen)	12,39
JavaScript	13,38	13,13	-1,84	Базовый стабильный (Evergreen)	12,57
SQL	22,95	19,04	-17,03	Локальная стабилизация	5,97

Технология	Доля D_t, %	Прогноз D_{t+14}, %	Прирост Δ, %	Классификация тренда	MAPE, %
Kubernetes	10,20	8,29	-18,70	Локальная стабилизация	15,42
PostgreSQL	13,21	8,74	-33,86	Локальная стабилизация	14,22
Python	18,40	12,11	-34,21	Локальная стабилизация	8,78

По результатам прогнозирования выделяются выраженные драйверы роста (Linux с приростом +27,3% и Docker с приростом +6,0%), отражающие смещение фокуса на инфраструктурные и платформенные компетенции. Средняя относительная ошибка аппроксимации MAPE составила 13,44% (для SQL — 5,97%), что свидетельствует об удовлетворительной предсказательной силе модели для стохастических рядов найма.

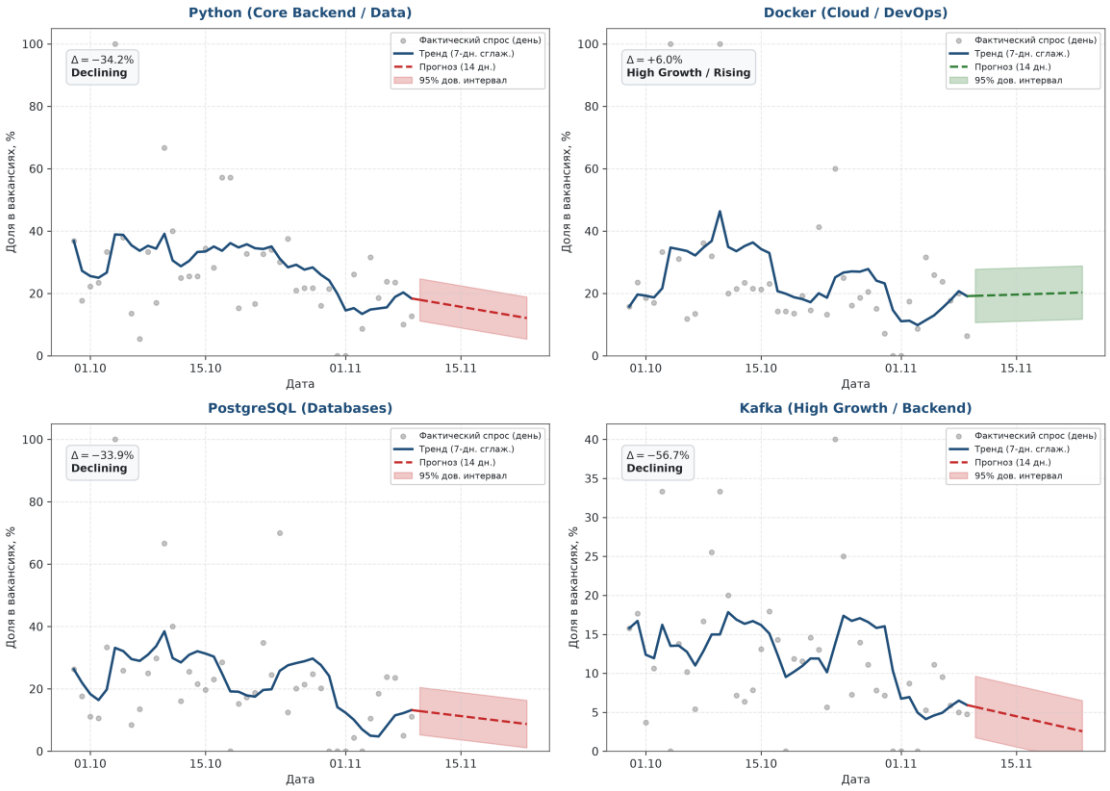


Рисунок 2 — Динамика рыночного спроса на ключевые технологии и прогноз моделью Холта на 14 дней с 95%-м доверительным интервалом

Заключение

Разработанный комплекс алгоритмов на языке Python обеспечивает автоматизированный сбор и сквозной анализ рынка IT-вакансий. Эмпирическое исследование 2 472 вакансий подтвердило гипотезу о наличии дифференцированных премий за технологический стек: навыки построения распределенных асинхронных архитектур (Go, RabbitMQ, Kafka, Kubernetes) обеспечивают статистически подтвержденную прибавку к медианной заработной

плате от 78% до 113% ($p < 0{,}001$). Модель Random Forest объясняет 56,3% дисперсии заработной платы при ошибке MAE = 1 452,5 BYN. Прогнозирование временных рядов моделью Холта зафиксировало опережающий рост спроса на навыки контейнеризации и системного администрирования Linux. Полученные результаты могут использоваться образовательными учреждениями при актуализации учебных планов и соискателями при формировании индивидуальных образовательных траекторий.

Список использованных источников:

1. Макаров, В. Л. Цифровая экономика: концептуальная архитектура экосистемы и моделирование / В. Л. Макаров, А. Р. Бахтизин // Экономика и математические методы. — 2020. — Т. 56, № 2. — С. 5–18.

2. Глухов, В. В. Математические методы и модели в экономике труда / В. В. Глухов, И. В. Ильин. — СПб. : Изд-во Политехн. ун-та, 2019. — 312 с.

3. Kuhn, P. What do online job ads tell us about the demand for skills? / P. Kuhn, H. Shen // Journal of Labor Economics. — 2023. — Vol. 41, no. 1. — P. 119–158.

4. Hastie, T. The Elements of Statistical Learning: Data Mining, Inference, and Prediction / T. Hastie, R. Tibshirani, J. Friedman. — 2nd ed. — New York : Springer, 2017. — 745 p.

5. Hyndman, R. J. Forecasting: Principles and Practice / R. J. Hyndman, G. Athanasopoulos. — 3rd ed. — Melbourne : OTexts, 2021. — 584 p.

6. McKinney, W. Python for Data Analysis: Data Wrangling with pandas, NumPy, and Jupyter / W. McKinney. — 3rd ed. — Sebastopol : O’Reilly Media, 2022. — 550 p.

7. Pedregosa, F. Scikit-learn: Machine Learning in Python / F. Pedregosa [et al.] // Journal of Machine Learning Research. — 2011. — Vol. 12. — P. 2825–2830.

8. СТП 01–2024. Общие требования к оформлению текстовых студенческих работ. — Минск : БГУИР, 2024. — 48 с.